

Diseño e implementación de un pipeline de datos para el análisis del macroentorno ecuatoriano

Bryan Raúl Andino Alcivar

Carrera de Computación, Universidad Técnica Particular de Loja (UTPL)

Dirección General de Tecnologías de la Información y Transformación Digital (DGTITD)

Loja, Ecuador

Resumen—Este artículo presenta el diseño e implementación de un pipeline de datos desarrollado durante el Prácticum de Ingeniería de Datos de la Universidad Técnica Particular de Loja. El objetivo fue integrar información pública del macroentorno ecuatoriano y convertirla en conjuntos de datos consistentes, reutilizables y adecuados para análisis visual. La solución siguió una organización por capas inspirada en la arquitectura Medallón. Los datos recolectados mediante procesos de automatización fueron almacenados inicialmente en Oracle; después, scripts en Python extrajeron, normalizaron y transformaron estructuras JSON con apoyo de *pandas* y *oracledb*. Los resultados se almacenaron en SQLite como 14 tablas Silver y se prepararon 10 conjuntos Gold orientados a preguntas analíticas concretas. Para el consumo final se generó un libro Excel consolidado que alimentó un tablero de tres páginas en Power BI. El flujo procesó 310 345 registros y permitió analizar la evolución económica, la concentración territorial y sectorial de la actividad económica y el empleo, y la relación entre bachilleres y empresas activas por provincia. El trabajo evidencia que una arquitectura sencilla y reproducible puede integrar fuentes heterogéneas y convertirlas en información comprensible sin requerir infraestructura de gran escala.

Index Terms—ingeniería de datos, pipeline de datos, ETL, RPA, arquitectura Medallón, Python, Power BI, macroentorno ecuatoriano

I. INTRODUCCIÓN

Las organizaciones disponen cada vez de más datos, pero la existencia de información no garantiza que esta pueda utilizarse directamente para responder preguntas. Antes de llegar a un reporte o a un tablero, los datos deben ser obtenidos, revisados, limpiados, estructurados y preparados de forma consistente. Reis y Housley describen la ingeniería de datos como el conjunto de prácticas que permite mover información a lo largo de su ciclo de vida y hacerla disponible para usos posteriores [1]. De forma complementaria, Kleppmann señala que las decisiones relacionadas con almacenamiento, transformación y acceso condicionan la confiabilidad y mantenibilidad de los sistemas intensivos en datos [2].

Esta necesidad se hace más evidente cuando la información proviene de fuentes distintas. Un mismo análisis puede combinar archivos con codificaciones diferentes, campos anidados, nombres de columnas inconsistentes, fechas en múltiples formatos y valores que requieren normalización, problemas frecuentes dentro de las etapas de preparación de datos descritas en pipelines reales [3], [4]. En estudios sobre pipelines reales, Biswas, Wardat y Rajan muestran que la adquisición y preparación de datos aparecen de manera recurrente en los

flujos de ciencia de datos y concentran una parte importante del trabajo práctico [4]. Asimismo, Mbata, Sripada y Zhong agrupan las herramientas actuales de ingeniería de datos en categorías relacionadas con ETL/ELT, integración, ingesta, transformación y orquestación [3].

El presente trabajo se desarrolló en el marco del Prácticum de Ingeniería de Datos de la Dirección General de Tecnologías de la Información y Transformación Digital de la Universidad Técnica Particular de Loja. El reto consistió en construir un flujo capaz de integrar indicadores del macroentorno ecuatoriano provenientes de distintas fuentes públicas y convertirlos en información lista para análisis. La solución implementada parte de datos recolectados por procesos de automatización, los consolida en Oracle y posteriormente los transforma mediante scripts en Python hasta producir conjuntos analíticos consumidos en Power BI.

El proyecto se orientó a responder tres preguntas: 1) ¿cómo ha evolucionado la economía ecuatoriana en los últimos veinte años?, 2) ¿en qué sectores y provincias se concentra la actividad económica y el empleo?, y 3) ¿dónde están los bachilleres y cuántas empresas hay por provincia? A diferencia de un estado del arte general, este artículo relaciona los conceptos revisados durante el Prácticum con la ruta de implementación seguida y con los resultados obtenidos en el dashboard final.

II. MARCO CONCEPTUAL

II-A. Pipelines de datos

Un pipeline de datos puede entenderse como una secuencia de tareas que transporta y transforma información desde uno o varios orígenes hasta un destino preparado para su consumo. Las tareas pueden incluir extracción, validación, limpieza, normalización, integración, agregación y publicación. Mbata et al. destacan que los pipelines modernos no se limitan al movimiento de datos, sino que combinan herramientas de ingesta, transformación y gestión del flujo [3].

En este proyecto, el pipeline fue concebido como un proceso reproducible. Esto significa que, ante una nueva actualización de las fuentes, el procesamiento puede volver a ejecutarse siguiendo las mismas reglas, en lugar de depender de correcciones manuales realizadas cada vez. Esta característica es importante porque reduce la dependencia del conocimiento informal y facilita revisar en qué etapa se generó un resultado.

II-B. ETL, ELT y separación por capas

Los enfoques ETL y ELT describen distintos órdenes para extraer, transformar y cargar datos y constituyen patrones centrales dentro de la ingeniería de datos moderna [1], [3]. En entornos reales, ambos pueden combinarse según la arquitectura y las necesidades del sistema. El flujo desarrollado utiliza una lógica híbrida: primero se cargan datos crudos obtenidos por automatización en Oracle y, después, se extraen y transforman para crear estructuras relacionales y conjuntos analíticos.

La separación entre datos crudos, datos depurados e información lista para análisis se relaciona con el principio de progresiva refinación presente en arquitecturas modernas. Armbrust et al. proponen el enfoque *Lakehouse* como una forma de combinar flexibilidad de almacenamiento y capacidades analíticas [5]. Dentro de este contexto, la arquitectura Medallón organiza los datos en capas Bronze, Silver y Gold, incrementando gradualmente su calidad y estructura [6]. En este proyecto se adoptó esa lógica de manera pragmática, sin requerir una plataforma Lakehouse completa.

II-C. Calidad y normalización

La calidad de datos es una condición necesaria para que un análisis sea interpretable y confiable [7]. Ehrlinger y Wöß destacan que las prácticas de calidad suelen incluir perfilado, medición, monitoreo y limpieza [7]. En la implementación realizada, la calidad se abordó mediante reglas concretas: conversión de tipos, corrección de codificación, estandarización de nombres, tratamiento de estructuras JSON y normalización de campos geográficos.

Una dificultad relevante fue la heterogeneidad. Algunos indicadores tenían estructuras planas, mientras que otros contenían objetos JSON anidados o valores serializados más de una vez. La normalización permitió convertir esa variedad en tablas con columnas utilizables en consultas y visualizaciones.

II-D. Automatización y RPA

La automatización robótica de procesos puede reducir tareas repetitivas de captura y transferencia de datos mediante la ejecución automatizada de actividades basadas en reglas [8], [9]. Enríquez et al. muestran que RPA se utiliza ampliamente para automatizar actividades basadas en reglas y la interacción con sistemas digitales [8]. Estudios recientes también han explorado su aplicación específica en recolección y análisis de datos [9].

En el proyecto, la automatización se ubica en el inicio del flujo: los procesos RPA recopilan información de las fuentes y la depositan en la tabla consolidada de Oracle. El trabajo desarrollado durante el Prácticum se concentró principalmente en la etapa posterior: consumir ese repositorio, interpretar los datos y construir las capas Silver y Gold.

III. TRABAJOS RELACIONADOS

La literatura sobre ingeniería de datos coincide en que la dificultad principal no está únicamente en almacenar grandes volúmenes, sino en construir procesos confiables para preparar y entregar información. Biswas et al. estudiaron pipelines

en diferentes escalas y encontraron patrones recurrentes de adquisición, preparación y análisis [4]. Mbata et al. revisaron herramientas de pipelines y muestran que el ecosistema actual se organiza alrededor de funciones complementarias más que de una única plataforma universal [3].

Desde la perspectiva arquitectónica, la propuesta Lakehouse de Armbrust et al. busca unificar características de los lagos y almacenes de datos [5]. Aunque la solución desarrollada aquí utiliza Oracle, SQLite y archivos Excel, adopta el mismo principio de separar responsabilidades y conservar una ruta clara desde los datos crudos hasta los datos de negocio.

En materia de automatización, Enríquez et al. identifican la expansión de RPA en entornos científicos e industriales [8]. Para este caso, la RPA funciona como mecanismo de ingesta, mientras que Python concentra la lógica de transformación. Esta separación permitió que la fase de procesamiento no dependiera del modo exacto en que cada fuente fue descargada.

Finalmente, el uso de herramientas de visualización permite cerrar el ciclo del dato al transformar los conjuntos preparados en representaciones que facilitan su exploración y comunicación [10]. Power BI integra capacidades de conexión, modelado y visualización orientadas a convertir datos en información accionable [10]. En el proyecto, esta capa final se utilizó para traducir los conjuntos Gold en indicadores y gráficos organizados alrededor de las preguntas del reto.

IV. METODOLOGÍA Y ARQUITECTURA IMPLEMENTADA

El trabajo se desarrolló de forma incremental, manteniendo una separación entre ingesta, transformación, preparación analítica y visualización, coherente con el principio de refinamiento progresivo de los datos [5], [6]. Primero se verificó la conexión con Oracle y la estructura de la tabla `TAB_CONSOLIDADO`; después se construyó el procesamiento de cada indicador; posteriormente se consolidaron las salidas Silver y Gold; y, finalmente, se diseñó el dashboard en Power BI. La Figura 1 resume la arquitectura seguida.

IV-A. Capa de entrada: Oracle como repositorio Bronze

Los datos recolectados por RPA se almacenaron en Oracle dentro de `TAB_CONSOLIDADO`. La tabla contenía 14 grupos de indicadores asociados con información económica, empresarial, educativa y laboral. Entre los conjuntos de mayor tamaño se encontraron el directorio de Superintendencia de Compañías, con 224 428 registros; el ranking empresarial, con 32 816; los registros MINEDUC, con 16 275; y dos conjuntos censales de 11 405 registros cada uno. El total procesado fue de 310 345 registros.

Esta etapa se consideró Bronze porque conserva la información cercana a su forma de origen, siguiendo la lógica de una capa inicial destinada a mantener los datos con el menor nivel posible de transformación [6]. Su principal función fue servir como punto central de entrada para el procesamiento posterior.

IV-B. Transformación y construcción de Silver

La conexión a Oracle se realizó desde Python mediante `oracledb`. Los scripts consultaron los registros por indicador




Figura 1. Arquitectura implementada para el pipeline del macroentorno ecuatoriano.

y procesaron el contenido JSON. En algunos casos, el JSON se encontraba serializado dos veces, por lo que fue necesario realizar una segunda deserialización antes de normalizarlo. Para estructuras anidadas se utilizó `pandas.json_normalize`.

Durante la transformación se aplicaron reglas de limpieza y estandarización. Se corrigieron problemas de codificación, se convirtieron campos a tipos numéricos y fechas cuando correspondía, se homogeneizaron nombres de provincias y se serializaron valores residuales de tipo lista o diccionario antes de almacenarlos en SQLite. Como resultado se generaron 14 tablas Silver, una por cada grupo principal de indicadores.

IV-C. Preparación de los conjuntos Gold

Las tablas Silver sirvieron como base para construir 10 conjuntos Gold orientados a análisis. Estos incluyeron tendencias del PIB, precio del petróleo, IEE, VAB por provincia y sector, empresas por provincia, bachilleres por provincia, relación bachilleres-empresas y empleo. El objetivo de Gold no fue conservar todo el detalle de origen, sino entregar información resumida y directamente utilizable por el dashboard, de acuerdo con el principio de preparar productos de datos orientados al consumo analítico [5], [6].

En la etapa de integración con Power BI apareció un problema práctico: algunos valores decimales importados desde CSV fueron interpretados incorrectamente por la configuración regional, produciendo magnitudes alteradas. Para evitar este error se generó un libro Excel consolidado, `gold_macroentorno.xlsx`, con una hoja por conjunto Gold. Esta decisión permitió conservar correctamente los valores numéricos y simplificó la carga del modelo en Power BI.

IV-D. Orquestación como exploración complementaria

Durante las prácticas también se evaluó Prefect como herramienta de orquestación. Prefect permite convertir funciones de Python en flujos con seguimiento de estados y manejo de fallos [11]. Sin embargo, en este proyecto su uso se mantuvo como una exploración adicional y no como dependencia obligatoria del pipeline final. La versión entregada puede ejecutarse mediante los scripts desarrollados sin requerir un orquestador externo.

V. HERRAMIENTAS Y TECNOLOGÍAS

La Tabla I resume las herramientas efectivamente utilizadas y su función dentro del flujo.

La elección de herramientas respondió al alcance académico y a los recursos disponibles. El uso de herramientas ligeras y especializadas por etapa es coherente con la diversidad de

Cuadro I
STACK TECNOLÓGICO UTILIZADO

Herramienta	Función en el proyecto
RPA	Recolección automatizada y entrega de datos al repositorio inicial.
Oracle	Almacenamiento de los datos consolidados en la capa Bronze.
Python	Implementación de la lógica de extracción, transformación y carga.
pandas	Limpieza, normalización y manipulación tabular de datos.
oracledb	Conectividad entre los scripts de Python y Oracle.
SQLite	Almacenamiento local de las tablas Silver y conjuntos Gold.
SQL	Consultas de validación y preparación de información.
Excel	Contenedor consolidado para transferir los conjuntos Gold a Power BI.
Power BI	Construcción del dashboard interactivo de tres páginas.
Git/GitHub	Control de versiones y publicación del proyecto.

funciones que presentan los ecosistemas de pipelines actuales [3]. SQLite permitió trabajar localmente sin necesidad de administrar un servidor adicional, mientras que Python y pandas facilitaron adaptar la lógica a fuentes con estructuras diferentes. Esta combinación permitió construir un pipeline comprensible, ejecutable y fácil de mantener para el nivel del proyecto.

VI. RESULTADOS

El principal resultado fue un flujo completo desde los datos consolidados por RPA hasta un dashboard interactivo. A nivel de procesamiento, se integraron 310 345 registros, se generaron 14 tablas Silver y 10 conjuntos Gold. A nivel de consumo, el dashboard quedó organizado en tres páginas, cada una asociada con una pregunta analítica.

VI-A. Evolución de la economía ecuatoriana

La primera página presenta la evolución del PIB real y su variación anual durante los últimos veinte años. Incluye indicadores del PIB per cápita, la variación del último año y una clasificación del ciclo económico. También incorpora botones para visualizar ventanas de cinco, diez y veinte años. En la versión final del tablero, el último dato mostrado registra una variación de -2,66 % y se clasifica como contracción. La combinación de una línea de PIB real y barras de variación facilita observar periodos de crecimiento y caída en una misma vista.

VI-B. Actividad económica y empleo por provincia y sector

La segunda página analiza la concentración territorial y sectorial de la actividad económica e incorpora un indicador específico de empleo. El tablero identifica a Guayas como la




Figura 2. Página 1 del dashboard: evolución de la economía ecuatoriana y del ciclo económico.

provincia con mayor actividad dentro del conjunto analizado y al comercio como el sector de mayor peso agregado. Un gráfico de dona muestra la distribución sectorial y un ranking presenta las provincias con mayor actividad económica. Además, el KPI de empleo identifica a agricultura y pesca como el sector con mayor número de personas ocupadas dentro de los datos procesados. La interacción entre elementos permite seleccionar una provincia y observar cómo cambia la composición por sectores.

VI-C. Bachilleres y empresas por provincia

La tercera página compara la cantidad de bachilleres registrada en el conjunto analizado con la presencia de empresas activas por provincia. El tablero muestra 181 mil empresas activas y ubica a Guayas como la provincia con mayor número de bachilleres en los datos procesados. Además, se calculó un indicador de bachilleres por empresa activa, que permite identificar territorios donde la relación entre población estudiantil y tejido empresarial es más alta. Este indicador no pretende medir empleabilidad por sí solo, pero sí ofrece una forma sencilla de detectar diferencias territoriales que pueden ser analizadas con mayor profundidad.

VII. DISCUSIÓN

La experiencia confirmó que el mayor esfuerzo de un proyecto de datos no siempre se encuentra en el gráfico final. La principal complejidad apareció al integrar fuentes con estructuras diferentes y convertirlas en un modelo coherente. Esta observación coincide con la literatura que sitúa la

preparación y transformación como actividades centrales de los pipelines reales [4].

La separación por capas resultó útil por razones prácticas y coincide con enfoques que proponen separar progresivamente los datos crudos de los conjuntos preparados para consumo analítico [5], [6]. Mantener el origen en Oracle permitió conservar un punto de entrada independiente de las transformaciones; las tablas Silver facilitaron depurar y revisar cada indicador; y los conjuntos Gold evitaron que Power BI tuviera que reconstruir toda la lógica de negocio en cada visualización. El beneficio principal de la arquitectura no fue utilizar nombres Bronze, Silver y Gold, sino separar responsabilidades y reducir el acoplamiento entre las etapas.

Otro aprendizaje importante fue que la interoperabilidad entre herramientas puede generar problemas incluso cuando los datos ya están limpios. El error de interpretación decimal al importar CSV en Power BI mostró que la calidad no depende únicamente del contenido, sino también del formato de intercambio. La generación del libro Excel consolidado fue una solución sencilla, pero efectiva, para mantener los valores correctos y continuar con el análisis.

El proyecto también mostró la conveniencia de distinguir entre herramientas obligatorias y herramientas exploratorias. Las plataformas de orquestación permiten supervisar estados, dependencias y fallos dentro de un flujo de datos [11]; en este caso, Prefect permitió comprender este concepto y probar flujos administrados, pero la solución final se mantuvo ejecutable con scripts convencionales. Para un proyecto académico de este alcance, esta decisión evitó añadir complejidad innecesaria y




Figura 3. Página 2 del dashboard: concentración de la actividad económica por provincia y sector, con indicador del sector de mayor empleo.



Figura 4. Página 3 del dashboard: comparación de bachilleres y empresas activas por provincia.

permitió concentrarse en la lógica del pipeline.

Entre las limitaciones se encuentra que los indicadores provienen de periodos y granularidades distintas. Por tanto, las

comparaciones visuales deben interpretarse según el contexto de cada fuente. Asimismo, la relación entre bachilleres y empresas es descriptiva y no debe asumirse automáticamente

como una medida directa de empleo, demanda laboral o inserción profesional. El valor del dashboard está en facilitar la exploración y plantear nuevas preguntas a partir de datos integrados.

VIII. CONCLUSIONES

El Prácticum permitió aplicar conceptos de ingeniería de datos en un caso real de integración de información pública del Ecuador. El principal logro fue construir una ruta reproducible que conecta la recolección automatizada con la limpieza, estructuración, preparación analítica y visualización de los datos.

La arquitectura por capas facilitó trabajar con fuentes heterogéneas sin mezclar los datos crudos con los resultados preparados para análisis. Oracle funcionó como repositorio inicial, Python y pandas concentraron las reglas de transformación, SQLite permitió almacenar las tablas procesadas y los conjuntos Gold sirvieron como una capa orientada al consumo. El uso de Excel como puente hacia Power BI resolvió un problema concreto de formatos numéricos y mostró la importancia de adaptar la arquitectura a las condiciones reales del proyecto.

El dashboard final demostró que un pipeline de datos no termina cuando los registros han sido limpiados. Su propósito se completa cuando la información puede ser interpretada de manera clara. Las tres páginas construidas permiten observar la evolución económica, comparar la actividad económica por territorio y sector, identificar el sector con mayor empleo y explorar la relación entre bachilleres y empresas activas por provincia.

Finalmente, el proyecto evidencia que los principios de ingeniería de datos pueden adaptarse a distintos niveles de infraestructura siempre que exista una separación clara de responsabilidades, una lógica reproducible y una ruta definida

desde la ingesta hasta el consumo [1], [3]. Una solución compuesta por herramientas accesibles puede ser suficiente cuando existe una separación clara de etapas, reglas de transformación reproducibles y una conexión directa entre las preguntas analíticas y los datos preparados para responderlas.

REFERENCIAS

- [1] J. Reis and M. Housley, *Fundamentals of Data Engineering: Plan and Build Robust Data Systems*. Sebastopol, CA, USA: O'Reilly Media, 2022.
- [2] M. Kleppmann, *Designing Data-Intensive Applications*. Sebastopol, CA, USA: O'Reilly Media, 2017.
- [3] A. Mbata, Y. Sripada, and M. Zhong, "A Survey of Pipeline Tools for Data Engineering," *arXiv preprint arXiv:2406.08335*, 2024.
- [4] S. Biswas, M. Wardat, and H. Rajan, "The Art and Practice of Data Science Pipelines: A Comprehensive Study of Data Science Pipelines in Theory, in-the-Small, and in-the-Large," in *Proc. 44th IEEE/ACM Int. Conf. Software Engineering (ICSE)*, 2022, pp. 2091–2103, doi: 10.1145/3510003.3510057.
- [5] M. Armbrust, A. Ghodsi, R. Xin, and M. Zaharia, "Lakehouse: A New Generation of Open Platforms that Unify Data Warehousing and Advanced Analytics," in *Proc. 11th Conf. Innovative Data Systems Research (CIDR)*, 2021.
- [6] Databricks, "What is the medallion lakehouse architecture?," 2026. [Online]. Available: <https://docs.databricks.com/aws/en/lakehouse/medallion>. Accessed: Jul. 23, 2026.
- [7] L. Ehrlinger and W. Wöß, "A Survey of Data Quality Measurement and Monitoring Tools," *Frontiers in Big Data*, vol. 5, Art. no. 850611, 2022, doi: 10.3389/fdata.2022.850611.
- [8] J. G. Enríquez, A. Jiménez-Ramírez, F. J. Domínguez-Mayo, and J. A. García-García, "Robotic Process Automation: A Scientific and Industrial Systematic Mapping Study," *IEEE Access*, vol. 8, pp. 39113–39129, 2020.
- [9] K. Usman, T. M. Hayath, M. Shafiulla, and Dadapeer, "Robotics Process Automation Technologies for Data Collection and Analysis," in *Proc. 15th Int. Conf. Computing Communication and Networking Technologies (ICCCNT)*, 2024, doi: 10.1109/ICCCNT61001.2024.10725006.
- [10] Microsoft, "What is Power BI?," 2026. [Online]. Available: <https://learn.microsoft.com/en-us/power-bi/fundamentals/power-bi-overview>. Accessed: Jul. 23, 2026.
- [11] Prefect Technologies, "Prefect: Introduction," 2026. [Online]. Available: <https://docs.prefect.io/v3/get-started>. Accessed: Jul. 23, 2026.