

Universidad Técnica Particular de Loja
Dirección General de Tecnologías de la Información y
Transformación Digital

**Prácticum Interno — Datos — Ingeniería, Analítica y
Visualización**

Retos de introducción con dataset AMIE — MINEDUC Ecuador ·
Semana 3

Nombre: Raúl Andino

1. Introducción

Este trabajo fue realizado utilizando el conjunto de datos AMIE del Ministerio de Educación ecuatoriano, que incluye información sobre las instituciones educativas en la nación. Este conjunto de datos posibilita el análisis de variables como matrícula estudiantil, docentes, sostenimiento, año lectivo, provincia y cantón.

El objetivo principal fue construir un pequeño pipeline de datos, partiendo de archivos CSV originales, pasando por una base de datos SQLite, una limpieza con Python y finalmente la elaboración de un dashboard en Power BI. Este proceso responde al reto de la línea de Datos, donde se solicita limpiar el dataset AMIE, cargarlo en SQLite y construir un dashboard con visualizaciones analíticas.

2. Objetivo

Limpiar, integrar y preparar los datos del conjunto de datos AMIE - MINEDUC con el objetivo de crear una base de datos bien estructurada y un panel en Power BI que facilite la contestación a cuestiones relacionadas con la matrícula, el sostenimiento de las instituciones educativas y el desarrollo de entidades activas en Ecuador.

3. Herramientas utilizadas

Las siguientes herramientas fueron empleadas para la realización del trabajo:

DB Browser for SQLite: con el fin de examinar la base de datos e importar los archivos CSV originales.

SQLite: se utiliza para guardar los datos importados.

Python: para automatizar la limpieza.

Pandas: para fusionar tablas, limpiar columnas, transformar datos y crear el archivo depurado.

Visual Studio Code: como programa para editar código.

Power BI Desktop: para crear el panel de control final.

4. Descripción del dataset

El conjunto de datos empleado pertenece al Archivo Maestro de Instituciones Educativas, o AMIE. Esta base de datos incluye informes administrativos de escuelas ecuatorianas y ofrece información sobre la ubicación geográfica, el mantenimiento, el área, el tipo de educación (modalidad), el horario escolar, así como la cantidad de alumnos y profesores.

Al tratarse de un dataset real, se encontraron algunos problemas de calidad de datos, como nombres de columnas con caracteres especiales, diferencias de codificación, valores nulos, columnas extensas y datos que requerían estandarización antes de ser utilizados en Power BI. El documento guía del reto menciona precisamente que este dataset puede presentar problemas reales de calidad, como codificación Windows-1252, nombres de columnas sin tildes, valores nulos e inconsistencias entre totales y desagregaciones.

5. Proceso realizado

La organización de los archivos dentro de la carpeta del proyecto fue la primera acción. Los archivos originales se ubicaron en la carpeta data, la base de datos en la carpeta db, los archivos generados en la carpeta salida y el script de limpieza en la carpeta scripts.

Luego, se importaron los archivos CSV del MINEDUC a DB Browser for SQLite. Para la importación, se estableció el separador como punto y coma, se habilitó la opción de emplear la primera fila como nombres de las columnas y se ajustó la codificación para prevenir caracteres corruptos en columnas tales como año lectivo, cantón o institución.

Después, se elaboró y llevó a cabo un script en Python denominado `limpieza_desde_bd.py`. Este script realizó las siguientes acciones: leyó las tablas que se habían importado a la base SQLite, unió los datos históricos, limpió los nombres de las columnas, transformó aquellas que eran numéricas, eliminó duplicados y creó una tabla final denominada `instituciones_limpias`.

Al final, se creó un archivo CSV limpio con el nombre de `amie_limpio.csv`, que se cargó en Power BI para generar las visualizaciones del panel.

6. Decisiones de limpieza aplicadas

Se tomaron las siguientes resoluciones durante el proceso de limpieza:

Se normalizaron los nombres de las columnas para emplear denominaciones más sencillas, sin acentos, espacios ni caracteres especiales. En Python y Power BI, se modificaron nombres de columnas tales como "año lectivo", "provincia", "cantón", "sostenimiento" y "total de estudiantes" para que fueran más simples de gestionar.

Las columnas asociadas a alumnos y profesores, como `estudiantes_f`, `estudiantes_m`, `docentes_f` y `docentes_m`, así como `total_estudiantes` y `total_docentes`, también fueron transformadas en valores numéricos.

Se sustituyeron los valores nulos de las columnas numéricas por ceros, ya que se asumió que esos registros carecían de información reportada en dichas variables.

Se eliminaron, además, registros repetidos a partir del año académico y el código AMIE de la institución. Esto hizo posible que la misma institución no se repitiera en un mismo periodo.

Por último, se llevó a cabo una validación de consistencia entre el total de alumnos y la suma de los estudiantes hombres y mujeres. Se estableció una columna de diferencia para detectar inconsistencia potencial en los datos.

7. Resultados de la limpieza

Después de realizar el proceso de limpieza, se logró un conjunto de datos final que incluía:

Número total de filas tras la limpieza: 133705 registros.

Se crearon los siguientes archivos también:

db/amie_mineduc.db: base de datos SQLite que contiene las tablas depuradas y las importadas.

salida/diagnostico_limpieza.txt: archivo que contiene el diagnóstico del conjunto de datos. **salida/amie_limpio.csv:** archivo CSV definitivo utilizado en Power BI.

scripts/limpieza_desde_bd.py: script de Python que se emplea para automatizar el proceso de limpieza.

La tabla principal que se creó en SQLite recibió el nombre de:

instituciones limpias

8. Dashboard en Power BI

El archivo `amie_limpio.csv` fue la base de la construcción del tablero en Power BI. Siguiendo las preguntas analíticas que se pidieron en el reto, se hicieron tres visualizaciones principales y una tarjeta KPI. El documento del desafío solicita responder preguntas acerca de la matrícula total por provincia, la comparación entre instituciones fiscales y particulares en cada área de Loja y el progreso de las instituciones activas desde 2015 hasta 2024.

Visualización 1: Inscripción total por provincia para el periodo 2023-2024.

La primera representación gráfica presenta la cantidad total de alumnos por provincia para el año académico 2023-2024, al inicio. Esta gráfica hace posible determinar cuáles provincias tienen la matrícula estudiantil más alta.

El gráfico muestra que provincias como Guayas y Pichincha tienen una matrícula más alta, lo cual podría estar vinculado con su concentración poblacional elevada y el número superior de instituciones educativas.

Visualización 2: Comparación de instituciones fiscales y particulares por zona en Loja

La segunda visualización contrasta las instituciones fiscales y privadas en la provincia de Loja, separadas por áreas rurales y urbanas.

Esta gráfica permite ver la distribución de las instituciones en función de su sostenimiento y localización. En la zona rural, las instituciones fiscales son más predominantes, a diferencia de la zona urbana, donde hay más instituciones privadas.

Visualización 3: Avance de instituciones en funcionamiento entre 2015 y 2024

El tercer gráfico ilustra cómo ha cambiado la cantidad de instituciones activas desde el año escolar 2015-2016 hasta el 2023-2024. Se empleó el recuento distintivo del código AMIE para esta gráfica, con el propósito de contabilizar cada año a las instituciones únicas.

Esta visualización posibilita apreciar modificaciones en el número de instituciones registradas a través del tiempo y estudiar las tendencias generales del sistema educativo en Ecuador.

(KPI): Inscripción nacional 2023-2024

Se añadió, adicionalmente a las tres visualizaciones, una tarjeta KPI que presenta la matrícula total a nivel nacional para el periodo lectivo 2023-2024 Inicio.

Este indicador resume de manera breve el número total de alumnos registrados en el periodo más reciente que se ha examinado.

9. Conclusión

Este trabajo ha posibilitado que se conviertan los datos primarios del MINEDUC en información ordenada, depurada y que sirva para el análisis. Los archivos originales se incorporaron a una base SQLite por medio de DB Browser, mientras que la limpieza, la integración y la creación del archivo final se automatizaron utilizando Python y pandas.

Se pudo ver con mayor claridad, gracias al tablero de Power BI, la distribución de la matrícula por provincia, la comparación entre las entidades fiscales y privadas en Loja y el progreso de las instituciones activas entre 2015 y 2024.

Para concluir, el proceso realizado evidencia la relevancia de procesar y limpiar adecuadamente los datos antes de someterlos a análisis, puesto que un tablero de control fiable depende directamente de la calidad del conjunto de datos empleado.