

Avance 5

Implementación y ejecución del pipeline con Prefect Cloud

Durante este avance se trabajó en la automatización y orquestación del pipeline de datos del proyecto de macroentorno del Ecuador. El objetivo principal fue lograr que el proceso de limpieza, transformación y generación de datos pueda ejecutarse desde Prefect Cloud, en lugar de depender únicamente de una ejecución manual desde la computadora.


Para esto se utilizó el código desarrollado previamente en Python, el repositorio de GitHub del proyecto y la plataforma Prefect Cloud.

Actividades realizadas

Primero se conectó la cuenta de Prefect Cloud con el repositorio de GitHub:

Andino3680/Practicum1.2-Ingenieria-de-Datos

Esto permitió que Prefect tenga acceso al código almacenado en el repositorio y pueda utilizarlo para ejecutar el pipeline.



```
MINGW64/c/Users/User/Documents/Reto-final 1/Reto-final
Installed 35 packages in 443ms
✓ Logged in to Prefect Cloud

User@DESKTOP-JH0JT9K MINGW64 ~/Documents/Reto-final 1/Reto-final (main)
$ uvx prefect-cloud github setup
✓ Prefect Cloud GitHub integration complete

Connected repositories:
- Andino3680/Practicum1.2-Ingenieria-de-Datos

Deploy a function from your repo with:
prefect-cloud deploy <file.py:function> --from <github repo>

User@DESKTOP-JH0JT9K MINGW64 ~/Documents/Reto-final 1/Reto-final (main)
$
```

Después se modificó el archivo:

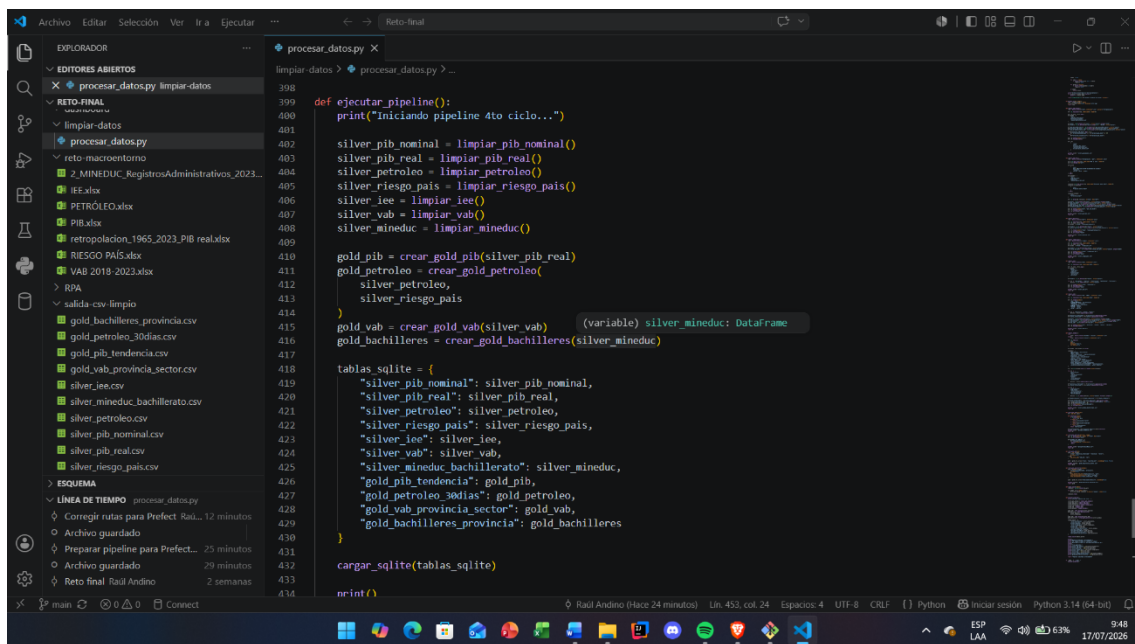
limpiar-datos/procesar_datos.py

El código original ejecutaba todo el proceso directamente desde el bloque principal del programa. Para poder utilizarlo con Prefect, se organizó la ejecución dentro de una función llamada:

ejecutar_pipeline()

Esta función se encarga de ejecutar todo el proceso de datos, incluyendo:


- Limpieza de los datos del PIB nominal y real.
- Procesamiento del precio del petróleo.
- Limpieza de los datos del Riesgo País.
- Procesamiento del IEE.
- Limpieza de los datos del VAB.
- Procesamiento de la información educativa del MINEDUC.
- Creación de las tablas de la capa Silver.
- Creación de las tablas de la capa Gold.
- Generación de los archivos CSV.
- Creación y actualización de la base de datos SQLite.



Luego se creó en Prefect Cloud un deployment llamado:

macroentorno-pipeline

Este deployment permite ejecutar el pipeline utilizando directamente el código almacenado en GitHub.



3. Problemas encontrados y solución

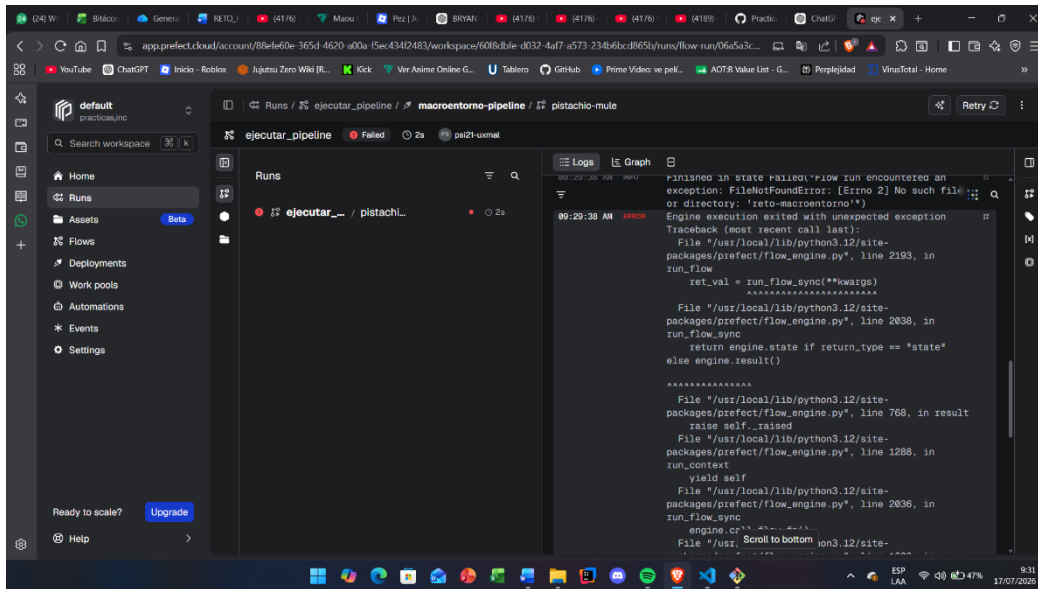
Durante la primera ejecución del pipeline en Prefect se presentó un error relacionado con las rutas de las carpetas.

El código originalmente utilizaba rutas como:

reto-macroentorno

Esto funcionaba cuando el programa se ejecutaba localmente, pero no cuando Prefect clonaba el repositorio en su propio entorno.

Para solucionar este problema se modificó el código para que las rutas se generen tomando como referencia la ubicación real del archivo procesar_datos.py.



Se agregó:

```
BASE_DIR = Path(__file__).resolve().parent.parent
```

A partir de esta ruta base se configuraron las carpetas de entrada, salida, base de datos y archivos SQL.

Después de realizar esta corrección, el código fue actualizado nuevamente en GitHub y se volvió a ejecutar el deployment desde Prefect Cloud.

```
1 import pandas as pd
2 from pathlib import Path
3 import unicodedata
4 import sqlite3
5
6 BASE_DIR = Path(__file__).resolve().parent.parent
7
8 carpeta_datos = BASE_DIR / "reto-macroentorno"
9 carpeta_salida = BASE_DIR / "salida-csv-limpio"
10 carpeta_db = BASE_DIR / "base-datos"
11 carpeta_sql = BASE_DIR / "sql"
12 carpeta_salida.mkdir(exist_ok=True)
13 carpeta_db.mkdir(exist_ok=True)
14 carpeta_sql.mkdir(exist_ok=True)
15
16 db_path = carpeta_db / "macroentorno.db"
17
```

4. Resultados obtenidos

La segunda ejecución del pipeline terminó correctamente con el estado:

Completed

Durante la ejecución se generaron correctamente los archivos de las capas Silver y Gold y también la base de datos SQLite.

Entre los resultados obtenidos se encuentran:

- silver_pib_nominal: 23 registros.
- silver_pib_real: 58 registros.
- silver_petroleo: 398 registros.
- silver_riesgo_pais: 307 registros.
- silver_iee: 191 registros.
- silver_vab: 20.890 registros.
- silver_mineduc_bachillerato: 4.141 registros.
- gold_bachilleres_provincia: 24 registros.

Con esto se comprobó que el pipeline puede ejecutarse correctamente desde Prefect Cloud utilizando el código almacenado en GitHub.

